

역기구학 교육 2일차 과제1 보고서. 김도훈, 2026406041

1.전반부 내용 정리(모델 기반)

휴머노이드 로봇의 모델 기반 보행은 수학적 모델을 이용하여 로봇의 움직임을 계산하고 제어하는 방식이다. 실제 휴머노이드 로봇은 많은 관절과 링크로 이루어져 있어 동역학 계산이 복잡하기 때문에 로봇을 단순화한 LIPM이 사용되었다. 초기에는 정현파 함수를 이용하여 CoM의 궤적을 만들었지만 로봇마다 진폭이나 주기를 직접 조절해야 한다는 문제가 있었다. 이후에는 LIPM을 이용하여 CoM과 ZMP의 관계를 계산하는 방식이 사용되었다. ZMP가 발의 지지 영역 안에 있도록 CoM의 움직임을 계산하여 안정적인 보행을 만들었다. 하지만 실제 환경에서는 착지 충격이나 울퉁불퉁한 지면과 같은 외란이 발생하기 때문에 목표 ZMP와 실제 ZMP 사이에 오차가 생길 수 있다. 이를 해결하기 위해 ZMP 피드백 제어가 사용되었다. 목표 ZMP와 실제 ZMP의 오차를 계산하고 CoM의 움직임을 수정하여 균형을 유지하는 방식이다. 이후 Kajita는 미래의 ZMP 궤적까지 미리 고려하여 CoM의 움직임을 계산하는 Preview Control을 제안하였다. 또한 CoM의 위치뿐만 아니라 속도까지 고려하기 위해 Capture Point가 사용되기 시작하였다. Capture Point는 현재 로봇의 움직임을 바탕으로 균형을 유지하기 위해 발을 어디에 디디야 하는지를 판단하는 데 사용된다. 작은 외란은 ZMP를 조절하여 버틸 수 있지만 큰 외란이 발생하면 이것만으로는 부족하기 때문에 풋스텝 위치와 스텝 시간도 조절하게 되었다. 로봇이 크게 밀리면 발을 더 멀리 놓거나 더 빠르게 디디는 방식으로 균형을 회복한다. 이러한 값을 실시간으로 계산하기 위해 MPC와 QP 같은 최적화 방법도 사용되었다. MPC는 미래의 로봇 움직임을 예측하면서 적절한 CoM과 풋스텝 위치를 계산하는 방법이다. 이후에는 다리뿐만 아니라 팔과 몸통의 움직임도 균형 제어에 사용하기 시작하였다. 이를 위해 CAM이 사용되었다. CAM은 CoM을 기준으로 로봇 전체가 얼마나 회전하려고 하는지를 나타내고 상체와 팔을 움직여 발생하는 회전 운동을 이용하여 균형을 잡을 수 있다. 기존 LIPM에 이러한 회전 효과를 추가하기 위해 LIPFM이 사용되었다. 결국 모델 기반 보행은 LIPM을 이용한 CoM과 ZMP 제어에서 시작하여 Capture Point를 이용한 균형 제어, 풋스텝 위치와 스텝 시간 조절, 그리고 상체와 전신의 CAM을 이용하는 방식으로 발전하였다.

2.후반부 내용 정리(학습 기반)

휴머노이드 로봇의 모델 기반 보행은 수학적 계산을 이용해서 로봇이 움직인다. 그런데 실제 환경에서는 마찰, 지면 상태 등 보행을 어렵게 하는 외부 요인이 많아 보행이 어려웠다. 이러한 문제를 해결하기 위해 로봇이 직접 많은 시행 착오를 겪으면서 학습하도록 하는 강화학습 방식이 시작되었다. 초기의 강화학습은 end-to-end 형태였다. 이 형태는 ZMP 같은 중간 계산을 직접 설계하지 않고 센서 정보를 바탕으로 관절 명령을 출력하도록 학습하는 방식이다. 이것은 로봇처럼 연속적인 행동 공간을 가진 문제에 강화 학습을 적용할 가능성을 보여주었다. 하지만 문제가 있었다. 휴머노이드 로봇은 관절이 많다. 그래서 하나의 신경망이 모든 관절을 제어 해야하고 강화 학습에 사용할 보상 함수 설계도 어려웠다. 가장 큰 문제점은 휴머노이드 로봇의 움직임 사람의 보행보다 지나치게 역동적이고 자연스럽지 못했다. 그래서 연구자들은 게임에서 실제 사람과 같은 움직임을 구현하기 위해 사람의 움직임 데이터를 사용하는 것을 보고 휴머노이드 로봇이 사람처럼 걸을 수 있도록 사람의 움직임을 Motion Capture 데이터로 사용하여 로봇이 따라하도록 학습시켰다. 이 방식으로 다양한 기업의 로봇들이 사람처

럼 걷기 시작했고 역동적인 동작도 수행하기 시작했다. 그리고 RNN 계열인 LSTM을 사용해서 과거 정보를 기억하게하여 로봇이 외란을 내부적으로 추론하게 해 강인한 sim-to-real 성능을 보이도록 했다. 또한 end-to-end 방식은 하나의 신경망이 모든 행동을 결정하기 때문에 복잡한 작업을 수행하기 어렵다는 문제가 있었다. 이를 해결하기 위해 HLC와 LLC로 역할을 나누는 계층적 구조가 사용되었다. 대표적인 DeepLoco에서 HLC는 로봇의 상태와 주변 지형을 이용해 발을 어디에 놓을지를 결정하고 LLC는 실제 관절을 움직여 해당 위치에 발을 놓도록 한다. 이러한 방식으로 기존 end-to-end 방식에서 어려웠던 험지 보행이나 공 드리블과 같은 복잡한 작업도 수행할 수 있게 되었다. 이후에는 모델 기반 제어와 강화학습을 함께 사용하는 방식도 연구되었다. 모델 기반 제어가 발 위치나 로봇의 궤적을 계산하고 강화학습이 이를 실제 로봇이 잘 따라가도록 제어하거나, 반대로 강화학습이 목표를 결정하고 모델 기반 제어가 실제 관절을 제어하는 방식이다. 최근에는 카메라나 라이다 센서를 이용하여 주변 지형을 Height Map으로 만들고 이를 강화학습의 입력으로 사용하는 연구도 진행되고 있다. 이를 통해 계단이나 험지와 같은 복잡한 지형을 인식하며 걸을 수 있게 되었다. 하지만 실제 센서에는 잡음과 측정 오차가 있기 때문에 이를 해결하기 위한 연구도 계속 진행되고 있다. 결국 강화학습 기반 휴머노이드 보행은 end-to-end 방식에서 시작하여 Motion Capture를 이용한 모방 학습, sim-to-real, 계층적 구조, 지형 정보를 이용한 보행으로 발전하였다. 최근에는 강화학습만 사용하는 것이 아니라 모델 기반 제어와 강화학습의 장점을 함께 사용하는 방향으로 연구가 진행되고 있다.

3.느낀점

논문을 읽으면서 수학적인 모델부터 지금의 학습 기반의 보행까지 굉장히 많은 시간과 개발이 있었을 것 같다는 생각을 했다. 특히 수학적인 모델로 보행을 할 땐 연구원분들께서 얼마나 많은 실패와 성공을 거두었는지 나에게는 상상조차할 수 없었다. 난 고등학교 때 휴머노이드 로봇을 다루어 봤다. 고등학생이라 논문에 나온 모델 기반, 학습 기반 보행을 할 수 없었고 그래서 모터의 각도를 조절하면서 휴머노이드 보행을 구현했다. 앞으로 전진하고 후진하고 좌회전 우회전하는 모션을 하나하나 각도 조절로 만들었다. 각도 조절로 만든 모션은 성능에 한계가 있다. 그 중 로봇이 전진을 하다가 휘는 문제가 고등학생인 나에게 가장 큰 한계점이 있었다. 난 이 논문을 읽으면서 우리가 그때 수학적인 계산을 통해 모션을 만들었다면 이러한 한계점을 해결하고 대회에서도 더 좋은 성과를 낼 수 있지 않았을까라는 생각을 했다. 이 논문에서 가장 인상 깊었던 내용은 게임 개발에서 게임 속 캐릭터의 움직임을 좀 더 자연스럽게 하기 위해 사람의 움직임 데이터를 사용하는 것에 영감을 얻어 휴머노이드 보행에도 이러한 방법을 적용한 것이 굉장히 인상깊었다. 그 이유는 고등학생 때까지 난 로봇의 움직임은 사람이 직접 다 만든것이라고 생각했었다. 하지만 사람이 직접 로봇의 모든 움직임을 만들어주는 것이 아니라 실제 사람의 동작 자체를 학습에 활용한다는 발상이 새롭게 느껴졌기 때문이다. 또한 앞으로 휴머노이드 보행은 제어만 중요한 것이아니라 로봇의 주변 환경 파악도 중요해질 것이라는 생각이 들었다. 모든 보행은 강화학습을 통해 인간의 움직임과 비슷해졌다. 하지만 실제 사람처럼 주변 환경을 파악해 보행 움직임을 다르게 가져가는 것을 구현해야 진짜 휴머노이드 보행이 완성되었다고 생각한다. 그래서 앞으로 난 이러한 연구를 위해 로봇학을 공부하고 학교 생활을 할 것이라는 새로운 목표가 생겼다.

4. 키워드 정리

CoM : Center of Mass. 로봇 전체의 무게중심을 의미한다.

ZMP : Zero Moment Point. 로봇이 지면과 접촉하고 있을 때 균형을 제어하기 위해 사용하는 중요한 기준점이다.

정현파 함수 : sin, cos처럼 일정한 주기로 반복되는 함수이다. 초기 휴머노이드 보행에서는 CoM의 좌우 움직임이나 반복적인 궤적을 만들 때 사용되었다.

ZMP 피드백 제어 : 목표 ZMP와 실제 ZMP의 차이를 계산하고 그 오차를 줄이도록 CoM의 움직임을 수정하는 제어 방법이다.

Kajita의 Preview Control : 현재 ZMP뿐만 아니라 미래에 이동해야 할 ZMP 궤적까지 미리 고려하여 CoM의 움직임을 계산하는 제어 방법이다.

Jerk : 가속도가 시간에 따라 얼마나 빠르게 변하는지를 나타내는 값이다. 위치를 세 번 미분한 값으로 표현할 수 있다.

Capture Point(CP) : 현재 CoM의 위치와 속도를 이용하여 로봇이 균형을 회복하기 위해 발을 어디에 디딜까 하는지를 판단하는 데 사용하는 점이다.

LIPM : Linear Inverted Pendulum Model. 휴머노이드 로봇의 복잡한 움직임을 단순화하기 위해 로봇을 거꾸로 세운 진자처럼 표현한 모델이다.

LIPFM : Linear Inverted Pendulum Plus Flywheel Model. 기존 LIPM에 플라이휠을 추가하여 상체나 팔의 회전 효과까지 표현할 수 있도록 만든 모델이다.

CAM : Centroidal Angular Momentum. 로봇의 CoM을 기준으로 로봇 전체가 얼마나 회전하려고 하는지를 나타내는 값이다. 팔이나 몸통을 움직여 균형을 잡는 데 사용할 수 있다.

Centroidal Moment : 로봇의 CoM을 기준으로 발생하는 회전 효과를 의미한다. 이 값의 적분과 관련된 값으로 CAM을 사용할 수 있다.

MPC : Model Predictive Control. 현재 상태만 보는 것이 아니라 미래의 로봇 움직임을 예측하면서 가장 적절한 제어 입력을 계산하는 방법이다.

QP : Quadratic Programming. 여러 조건을 만족하면서 가장 좋은 값을 찾는 최적화 방법이다. 풋스텝 위치나 스텝 시간, CAM 등을 계산할 때 사용할 수 있다.

Footstep : 로봇이 다음에 발을 디딜 위치를 의미한다.

Step Time : 한 발을 디딘 후 다음 발을 디딜 때까지의 시간을 의미한다. 큰 외란이 발생하면 발 위치뿐만 아니라 스텝 시간도 조절할 수 있다.

Support Polygon : 로봇의 발이 지면과 접촉하면서 만들어지는 지지 영역이다. 보행 안정성을 판단할 때 중요한 개념이다.

End-to-End : 센서 정보를 입력으로 받아 중간의 모델 기반 계산 없이 신경망이 바로 관절 명령을 출력하도록 학습하는 방식이다.

Reinforcement Learning : 로봇이 직접 시행착오를 반복하면서 보상을 많이 받을 수 있는 행동을 학습하는 방식이다.

Reward : 강화학습에서 로봇의 행동이 좋은 행동인지 나쁜 행동인지 평가하기 위해 주는 점수이다.

Policy : 현재 로봇의 상태를 보고 어떤 행동을 할지 결정하는 강화학습의 제어 규칙이나 신경망을 의미한다.

Observation : 강화학습의 Policy에 입력되는 로봇의 센서 정보나 주변 환경 정보를 의미한다.

Motion Capture : 실제 사람의 움직임을 센서를 통해 측정하고 데이터로 저장한 것이다. 로봇이 사람과 비슷한 움직임을 학습할 때 사용된다.

Reference Motion : 로봇이 따라하도록 설정한 기준 동작을 의미한다. Motion Capture 데이터가 Reference Motion으로 사용될 수 있다.

Imitation Learning : 사람이나 기존 동작 데이터를 로봇이 따라하도록 학습시키는 방법이다.

RNN : Recurrent Neural Network. 현재 입력뿐만 아니라 이전의 정보도 이용할 수 있는 신경망이다.

LSTM : Long Short-Term Memory. RNN 계열의 신경망으로 과거 정보를 비교적 오래 기억할 수 있다. 로봇의 이전 움직임이나 외란 정보를 이용하는 데 사용된다.

Hidden State : RNN이나 LSTM 내부에 저장되는 과거 정보이다. 이전 상태의 정보를 현재 제어에 사용할 수 있게 해준다.

Sim-to-Real : 시뮬레이션 환경에서 학습한 제어기를 실제 로봇에 적용하는 것을 의미한다.

저감속비 기어 : 감속비가 작은 기어이다. 마찰이나 회전 관성과 같은 비선형적인 요소가 상대적으로 적어 Sim-to-Real에 유리할 수 있다.

고감속비 기어 : 감속비가 큰 기어이다. 큰 토크를 얻기 쉽지만 마찰이나 기어 특성의 영향이 커져 시뮬레이션과 실제 로봇 사이의 차이가 커질 수 있다.

System Identification : 실제 로봇의 질량, 마찰, 모터 특성 등 물리적인 특성을 측정하여 모델의 파라미터를 알아내는 과정이다.

PD Gain Tuning : 로봇의 위치나 관절 제어에 사용하는 P 게인과 D 게인을 조절하는 과정이다.

계층적 구조 : 하나의 신경망이 모든 일을 처리하는 것이 아니라 상위 제어와 하위 제어로 역할을 나누는 구조이다.

HLC : High Level Controller. 로봇이 어디로 이동할지, 다음 발을 어디에 놓을지와 같은 큰 목표를 결정하는 상위 제어기이다.

LLC : Low Level Controller. HLC가 정한 목표를 실제로 수행하기 위해 관절을 어떻게 움직일지 결정하는 하위 제어기이다.

DeepLoco : HLC와 LLC를 사용한 대표적인 계층적 강화학습 구조이다. HLC가 풋스텝 위치를 결정하고 LLC가 실제 로봇의 관절을 움직여 해당 위치에 발을 놓도록 한다.

Swing Foot : 보행 중 지면에서 떨어져 다음 위치로 이동하고 있는 발을 의미한다.

Height Map : 로봇 주변 지형의 높낮이를 지도 형태로 표현한 정보이다. 로봇이 계단이나 험지를 인식할 때 사용할 수 있다.

LiDAR : 레이저를 이용하여 주변 물체나 지형까지의 거리를 측정하는 센서이다.

Depth Image : 일반 이미지와 다르게 각 픽셀에 물체까지의 거리 정보가 들어 있는 이미지이다.

Belief Encoder : 센서나 지형 정보가 얼마나 신뢰할 수 있는지를 판단하고, 그 정보를 얼마나 사용할지를 결정하도록 학습된 구조이다.

Attention : 여러 입력 정보 중 현재 상황에서 더 중요한 정보에 집중하도록 하는 방법이다.

DTC : Deep Tracking Control. 모델 기반 방법으로 가능한 전신 움직임이나 궤적을 계산하고, 강화학습이 그 궤적을 실제 로봇이 따라가도록 제어하는 방식이다.

SRB Model : Single Rigid Body Model. 로봇의 몸 전체를 하나의 강체처럼 단순화해서 표현하는 모델이다.

Centroidal Model : 로봇의 모든 관절 움직임을 직접 계산하기보다 CoM과 전체 운동량을 중심으로 로봇의 움직임을 표현하는 모델이다.

모델 기반 보행 : 로봇의 움직임을 수학적 모델로 표현하고 계산하여 보행을 제어하는 방식이다.

강화학습 기반 보행 : 로봇이 환경과 반복적으로 상호작용하면서 시행착오와 보상을 통해 보행 방법을 학습하는 방식이다.